


Problème Inverse en ElectroEncéphaloGraphie (EEG)

Amar Kachenoura^(1,2)

¹INSERM, U1099, Rennes, F-35000, France

²Univ de Rennes , LTSI, Rennes, F-35000, France




Qu'est-ce que l'épilepsie ?

- Maladie neurologique caractérisée par la répétition de crises
 - ➔ conséquences socioprofessionnelles importantes
- Fonctionnement anormal, aigu et transitoire de l'**activité électrique du cerveau**




Trouble neurologique le plus courant
1% de la population




- Epilepsies **pharmaco-résistantes (30%)** ➔ foyers épileptiques

Approches thérapeutiques?


- **Chirurgie** : résection du foyer épileptique
- **Prérequis** : localisation du ou des foyers épileptiques
 - ➔ utilisation de mesures intracérébrales de l'activité neuronale (**caractère invasif**)



- Coût onéreux du processus occasionnant une liste d'attente considérable
 - ➔ ~300 bilans préopératoires seulement par an pour environ 10 000 candidats à la chirurgie
- **Méthodes non invasives** : l'EEG ou la MEG?



La MagnétoEncéphaloGraphie




S. Baillet, J. C. Mosher, and R.M. Leahy. Electromagnetic brain mapping.

IEEE Signal Processing Magazine, 18(6):14–30, Nov. 2001. Avec permission.

- Champs magnétique issu de l'activité cérébrale enregistré en 1968 par David Cohen (physicien du MIT, spécialisé dans les blindages magnétiques)
- De l'ordre de 100 femtoteslas à la surface de la tête, soit 10 milliards de fois plus faible que le champs magnétique terrestre

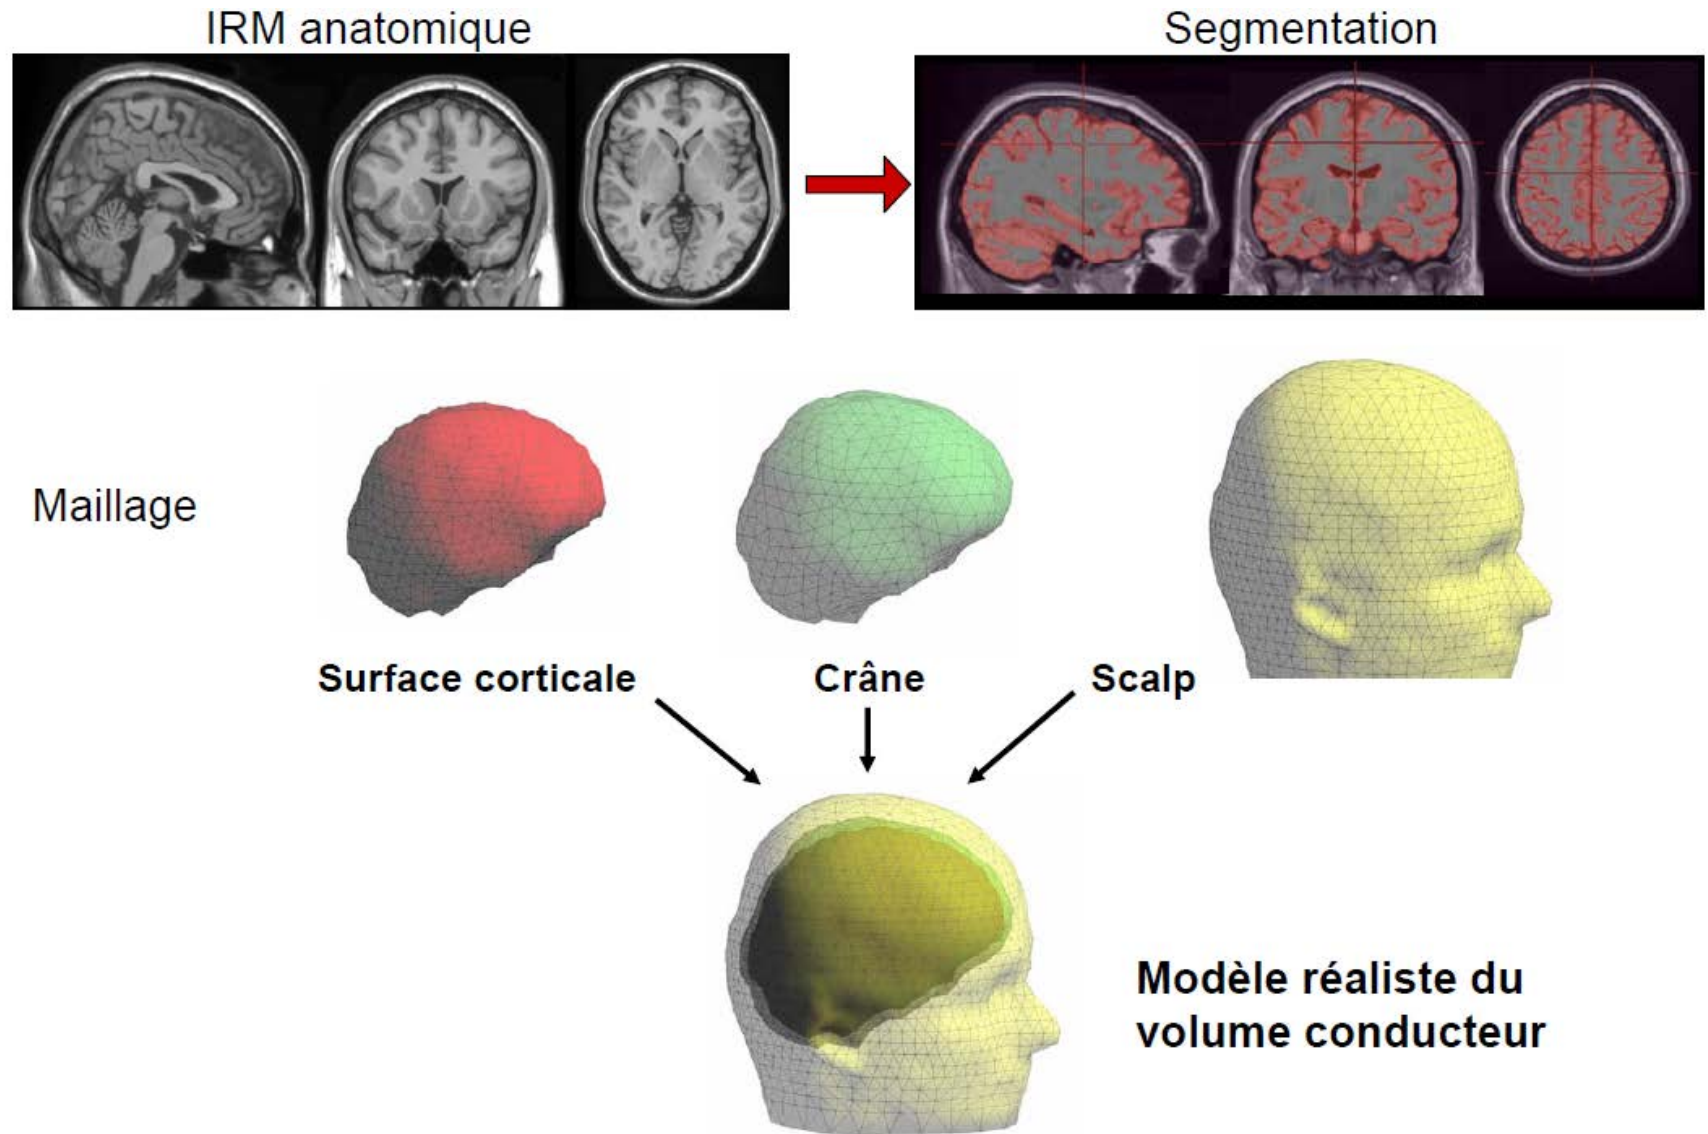
- Capteurs SQUID (Superconducting QUantum Interference Device, inventé par Jim Zimmerman en 1965) plongés dans un cryostat rempli d'hélium liquide à -269°C

L'ElectroEncéphaloGraphie




- Différences de **potentiel électrique** de l'ordre de la dizaine de microvolts
- Modalité la plus **rudimentaire** et la plus **ancienne** avec aujourd'hui au plus 256 électrodes
- **Premières expériences** menées sur des lapins et singes à même le cortex fin du XIXème
- Première **étude sur l'homme** en 1920 par Hans Berger (phys. allemand)


Modélisation du milieu : la tête



Modélisation de l'activité cérébrale : sources dipolaires distribuées



Maillage réaliste de la surface corticale



Segmentation
(gris/blanc)


Séparation des
2 hémisphères




Volume binaire

Reconstruction
de surface

Maillage
surfamique
(triangles)

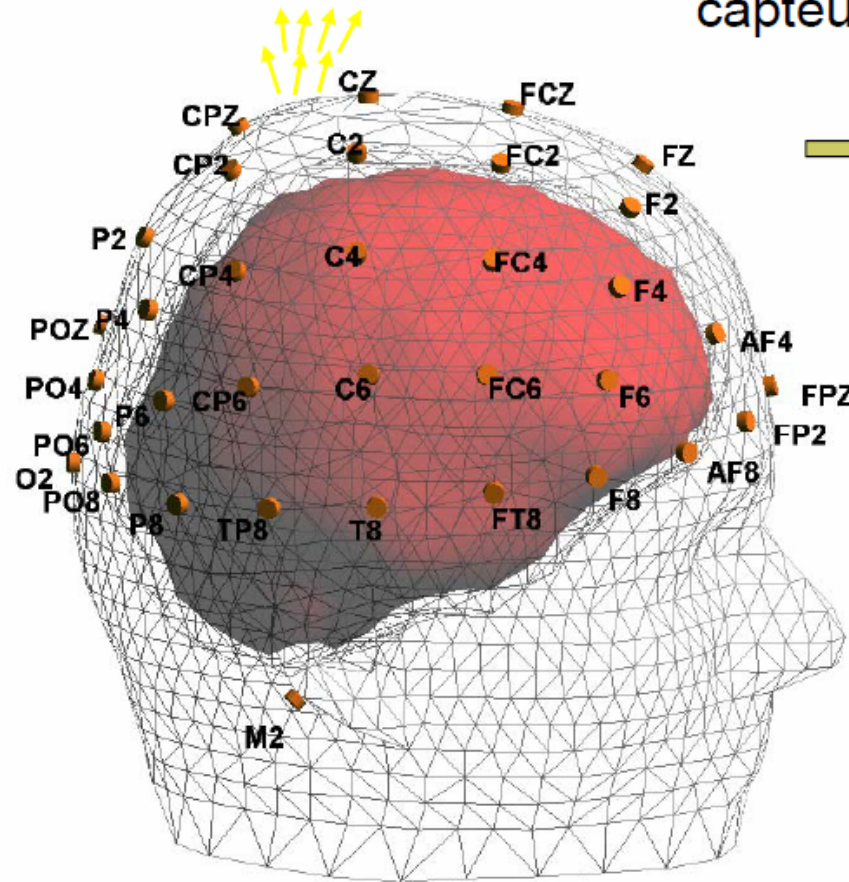


1 triangle = 1 dipôle



Modélisation du transfert de l'activité cérébrale vers les électrodes EEG de surface

Calcul du transfert entre un dipôle de courant situé à la surface du cortex et un capteur de scalp



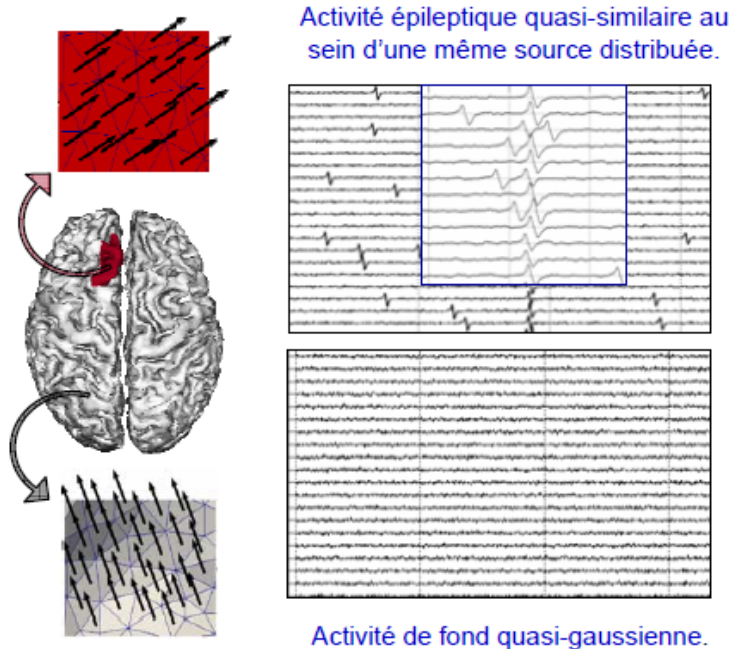
→ Approximation quasi-statique des équations de Maxwell

→ Calcul numérique complexe d'intégrales dans le cas d'un modèle de tête réaliste

→ Obtention du vecteur de transfert $a(\theta)$ pour chaque position θ

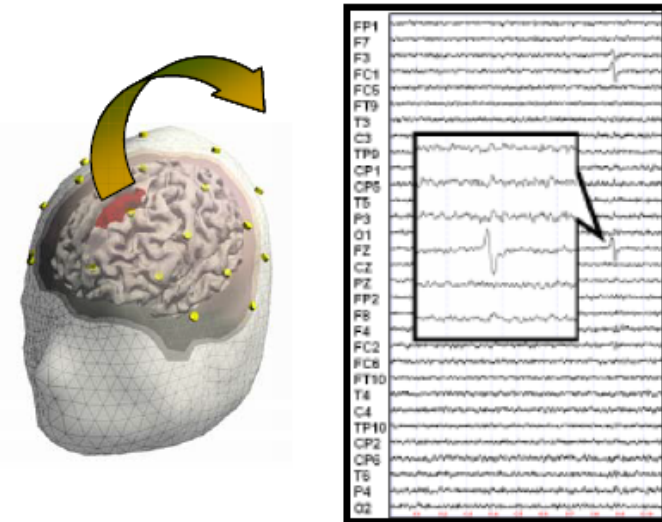
Localisation de générateurs épileptiques

Activité à la surface du cortex



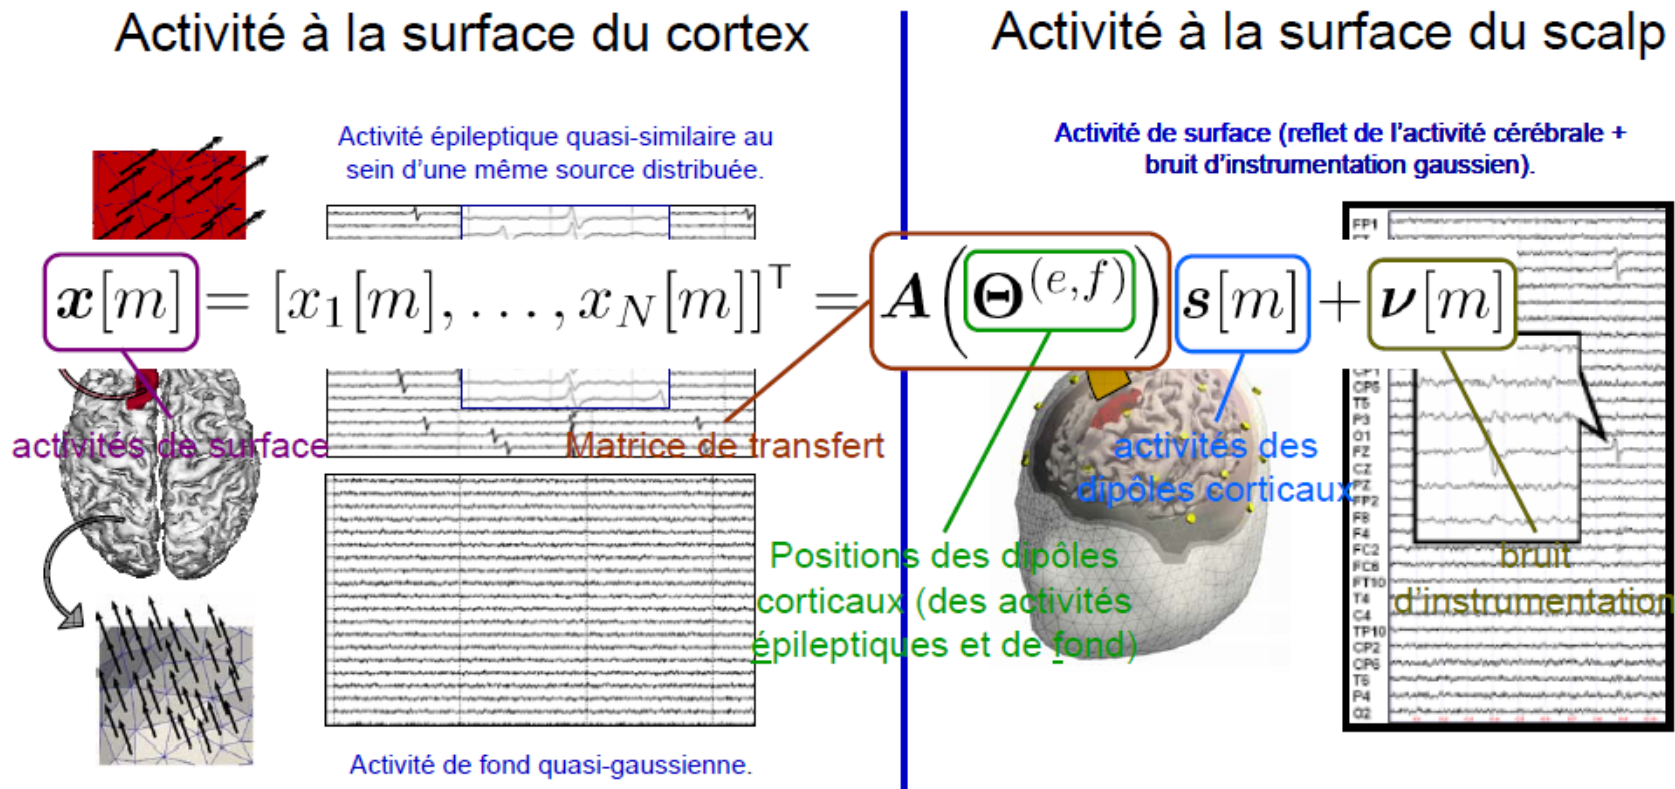
Activité à la surface du scalp

Activité de surface (reflet de l'activité cérébrale + bruit d'instrumentation gaussien).



- **Objectif** : localiser les générateurs cérébraux d'activité électrique pathologique et spatialement distribuée à partir de signaux de scalp
- **Difficultés** : problème mal posé, erreurs de modèle, faible SNR, etc,

Localisation de générateurs épileptiques



- **Objectif** : localiser les générateurs cérébraux d'activité électrique pathologique et spatialement distribuée à partir de signaux de scalp
- **Difficultés** : **problème inverse** mal posé, erreurs de modèle, faible SNR, etc,

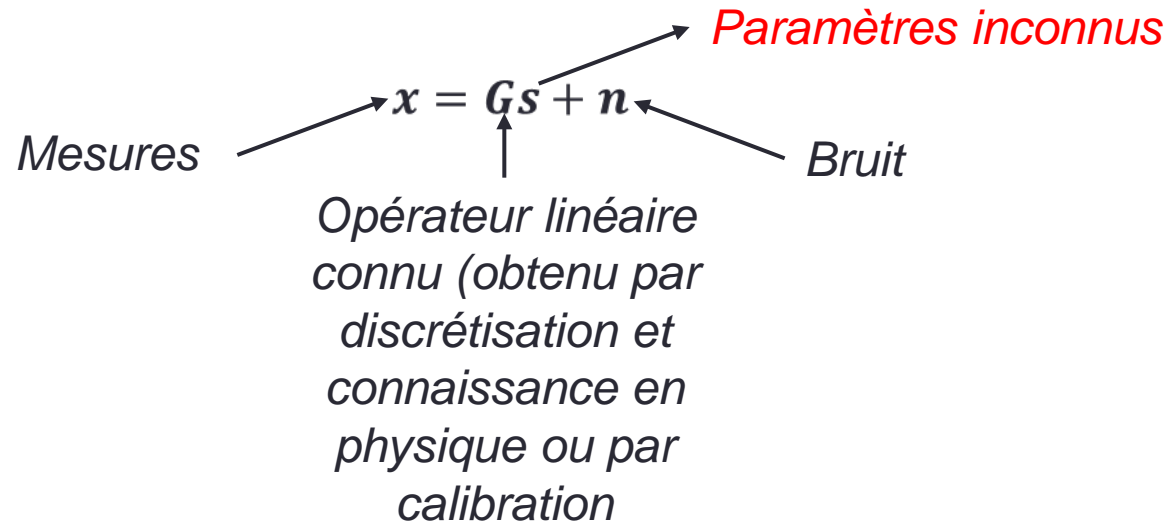


Problème inverse mal posé

- **Problème direct** : le modèle physique adopté donne x connaissant s de manière implicite ($G(s, x) = 0$) ou explicite ($x = G(s)$), sous forme d'équations différentielles, aux dérivées partielles, variationnelles, intégrales, etc.
- **Nécessite d'inverser le modèle physique** : l'inversion est un problème mathématique mal posé
- **Problème mathématique bien posé au sens d'Hadamard** : problème dont la solution *i)* existe, *ii)* est unique et *iii)* est stable (i.e. la solution dépend continûment de la donnée).
- **Problème mathématique mal pose** : une au moins des conditions *i)*, *ii)* et *iii)* n'est pas satisfaite

Méthode déterministes pour résoudre un PI

Problème inverse linéaire



Exemples :

- vectorisation d'images
- Localisation de sources (EEG, MEG, ECG, Télécommunication, ...)

Méthode déterministes pour résoudre un PI

3 cas différents en absence de bruit $x = Gs$ avec $G \in \mathbb{R}^{m \times n}$ de rang plein

$$\rightarrow \text{rang}(G) = \min(m, n)$$

Cas 1 $m = n$:

- Problème bien posé
- Solution unique $s = G^{-1}x$


Cas 2 $m > n$:

- Problème surdéterminé (plus de mesures que d'inconnues)
→ souvent pas de solution exacte

Exemple $\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} s$

- Solution la plus proche au sens des moindres carrés

$$\min_s \|x - Gs\|_F^2 + \lambda \|s\|_F^2$$



Méthode déterministes pour résoudre un PI

Solution

$$\begin{aligned} \min_s \| \underline{x} - G \underline{s} \|_F^2 &= \min_s (\underline{x} - G \underline{s})^T (\underline{x} - G \underline{s}) \\ \Rightarrow J &= \underline{x}^T \underline{x} + \underline{s}^T G^T G \underline{s} - 2 \underline{s}^T G^T \underline{x} \\ \frac{\partial J}{\partial \underline{s}} &= + 2 G^T G \underline{s} - 2 G^T \underline{x} = 0 \\ \Rightarrow 2(G^T G) \underline{s} &= + 2 G^T \underline{x} \\ \Rightarrow \underline{s} &= (G^T G)^{-1} G^T \underline{x} \quad \parallel (G^T G)^{-1} G^T = G^\# \\ &\quad \swarrow \text{Pseudo Inverse} \\ \text{Solution Instable en présence de Bruit} \end{aligned}$$

→ Définition par SVD

$$G = U \Sigma V^T = \begin{bmatrix} U_s & U_n \end{bmatrix} \begin{bmatrix} \Sigma_s & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} V_s^T \\ V_n^T \end{bmatrix}$$
$$= U_s \Sigma_s V_s^T$$

$\Rightarrow G^\# = V_s \Sigma_s^{-1} U_s^T$


Méthode déterministes pour résoudre un PI

Cas 3 $m < n$:

- Problème sous-déterminé (moins de mesures que d'inconnues)
→ une infinité de de solutions

Exemple $x = [1 \ 1] \begin{bmatrix} s_1 \\ s_2 \end{bmatrix} = s_1 + s_2$ (pour $x=1$)

- Pour obtenir une solution il faut de l'information supplémentaire ($s_1=1, s_1=s_2$).



Notion de régularisation

- Transformer un problème mal posé en un problème bien posé en ajoutant de l'information supplémentaires (a priori) / des contraintes → en pratique nous avons souvent des informations supplémentaires sur la solution attendue,
- Différentes méthodes (avec diffèrent a priori) existent, le choix de la méthode dépend de l'application,

Méthode déterministes pour résoudre un PI

Régularisation de TiKhonov (Tychonoff)

Idée : trouver la solution à norme minimale → en pratique, pour des raisons physiques, la solution la plus plausible est souvent celle qui est associées à une énergie minimale,

Problème d'optimisation modifié

$$\min_s \underbrace{\|x - Gs\|_F^2}_{\text{Erreur de reconstruction}} + \underbrace{\lambda \|s\|_F^2}_{\text{Terme de régularisation (prior)}}$$

Erreur de reconstruction
(data fit - attache aux données)

Paramètre de régularisation qui permet de
trouver un compromis entre l'erreur de
reconstruction et l'influence du prior

Terme de régularisation
(prior)

Formulation alternative

$$\min \|s\|_F^2 \text{ s. t. } \|x - Gs\|_F^2 \leq \beta$$

Paramètre de
régularisation

Méthode déterministes pour résoudre un PI

Solution

$$J = \|x - Gs\|_F^2 + \lambda \|s\|_F^2 = (x - Gs)^T (x - Gs) + \lambda s^T s$$

$$J = x^T x - 2s G^T x + s^T G^T G s + \lambda s^T s$$

$$\Rightarrow \frac{\partial J}{\partial s} = -2 G^T x + 2 G^T G s + 2 \lambda s = 0$$

$$\Rightarrow (G^T G + \lambda I) s = G^T x$$

$$\Rightarrow s = (G^T G + \lambda I)^{-1} G^T x$$

$n \times n$

↳ Souvent de très grande Dimension

↳ Contraint à la Pseudo inverse $G^\#$,
 λI assure la stabilité de la solution.

Méthode déterministes pour résoudre un PI

↳ Lemme d'inversion :

$$(B^T R^{-1} B + P^{-1})^{-1} B^T R^{-1} = P B^T (B P B^T + R)^{-1}$$

Donc :

$$\cancel{s = (G^T G + \lambda I)^{-1} G^T x} = \cancel{\lambda I G^T (G G^T + \lambda I)^{-1} x} \quad \left| \begin{array}{l} B^T = G^T, R^{-1} = I \\ P^{-1} = I. \end{array} \right.$$

$$\Rightarrow s = (G^T G + \lambda I)^{-1} G^T x$$

$$s = G^T \underbrace{(G G^T + \lambda I)^{-1} x}_{m \times m}$$

$m \times m$

↳ Souvent de Taille Bien plus raisonnable.

Méthode déterministes pour résoudre un PI

Choix du paramètre de régularisation λ

En pratique, on peut tester différentes valeurs de λ et choisir celle qui semble donner un bon résultat. Cependant, il est souvent nécessaire de choisir λ automatiquement. Pour ce faire, on utilise des heuristiques (règles pratiques empiriques).

Critère basé L-Curve

Tracer $\|s\|_F$ vs $\|x - Gs\|_F$ pour différents λ sur une échelle double logarithmique

- Pour montrer le compromis entre l'erreur de reconstruction et le terme régularisation;
- Fonction à décroissance monotone;
- Choisir λ au point associé avec la plus grande courbature (max de f'').

Principe d'incertitude (discrepancy principle)

L'idée est que l'erreur de reconstruction est due au bruit, Il faut choisir λ tel que :

$$\|x - Gs\|_F^2 \approx \lambda \|n\|_F^2$$

→ nécessite l'information sur le niveau du bruit.

Méthode déterministes pour résoudre un PI

Lien entre la régularisation de TiKhonov et le modèle probabiliste (TD)

Exercice : Soit $x \in \mathbb{R}^N$ un vecteur d'observations recueillies à partir d'un réseau de N électrodes tel que :

$$x = As + \nu \quad (1)$$

où $s \in \mathbb{R}^P$ est un vecteur de sources que l'on cherche à estimer, $A \in \mathbb{R}^{N \times P}$, $N \leq P$ est la matrice qui représente le transfert entre l'espace sources et l'espace observations et $\nu \in \mathbb{R}^N$ est le vecteur d'un bruit additif supposé gaussien $\mathcal{N}(0, \Sigma_\nu)$.

- Estimer le vecteur source s au sens de moindre carrée sous l'hypothèse énergie minimale de cette dernière (principe de régularisation de Tikhonov)
- Comparer le résultat obtenu de la question précédente avec celui obtenu sans considérer l'hypothèse de l'énergie minimale de sources (vu en cours)
- Supposons maintenant que x et s sont deux vecteurs aléatoires issus des processus stochastiques gaussiennes $\mathcal{X} \rightsquigarrow \mathcal{N}(x, \Sigma_{\mathcal{X}})$ et $\mathcal{S} \rightsquigarrow \mathcal{N}(0, \Sigma_{\mathcal{S}})$, respectivement. Montrer que l'estimation bayésienne de s est égale à celle trouvée au sens de moindre carrée avec la régularisation de Tikhonov.

Méthode déterministes pour résoudre un PI

Solution

- c. D'un point de vu probabiliste, \mathbf{x} et \mathbf{s} sont deux vecteurs aléatoires vus comme deux réalisations de deux processus stochastiques, \mathcal{X} et \mathcal{S} , respectivement. L'estimation bayésienne de \mathbf{s} par la probabilité à posteriori $p(\mathcal{S}|\mathcal{X})$ est basée, comme son nom l'indique, sur la théorème de Bayes :

$$p(\mathcal{S}|\mathcal{X}) = \frac{p(\mathcal{X}|\mathcal{S})p(\mathcal{S})}{p(\mathcal{X})} \quad (3)$$

où $p(\mathcal{X}|\mathcal{S})$ est la vraisemblance de \mathcal{X} par rapport au paramètre \mathcal{S} . $p(\mathcal{S})$ est l'a priori sur la paramètre \mathcal{S} et $p(\mathcal{X})$ est l'a priori sur les observations. Normalement $1/p(\mathcal{X})$ est considéré comme un facteur de normalisation. La solution recherchée \mathbf{s} , pourra être considérée comme la moyenne de la processus $\{\mathcal{S}\}$. Ainsi, estimer \mathbf{s} est possible par un calcul de la moyenne de la distribution à posteriori $p(\mathcal{S}|\mathcal{X})$. On sait maintenant que : $\mathcal{X} \rightsquigarrow \mathcal{N}(\mathbf{x}, \Sigma_{\mathcal{X}})$ et $\mathcal{S} \rightsquigarrow \mathcal{N}(0, \Sigma_{\mathcal{S}})$, alors :

$$p(\mathcal{S}) \approx \exp\left(-\frac{1}{2}\mathcal{S}^{\top}\Sigma_{\mathcal{S}}^{-1}\mathcal{S}\right) \quad (4)$$

$$p(\mathcal{X}) \approx \exp\left(-\frac{1}{2}(\mathcal{X} - \mathbf{x})^{\top}\Sigma_{\mathcal{X}}^{-1}(\mathcal{X} - \mathbf{x})\right) \quad (5)$$

$$\Rightarrow p(\mathcal{S}|\mathcal{X}) \approx \exp\left(-\frac{1}{2}(\mathcal{X} - \mathbf{x})^{\top}\Sigma_{\mathcal{X}}^{-1}(\mathcal{X} - \mathbf{x}) - \frac{1}{2}\mathcal{S}^{\top}\Sigma_{\mathcal{S}}^{-1}\mathcal{S}\right) \quad (6)$$

Méthode déterministes pour résoudre un PI

On sait aussi que $\mathcal{X} = \mathbf{A}\mathcal{S}$, alors :

$$\Rightarrow p(\mathcal{S}|\mathcal{X}) \approx \exp\left(-\frac{1}{2}(\mathbf{A}\mathcal{S} - \mathbf{x})^\top \Sigma_{\mathbf{A}\mathcal{S}}^{-1}(\mathbf{A}\mathcal{S} - \mathbf{x}) - \frac{1}{2}\mathcal{S}^\top \Sigma_{\mathcal{S}}^{-1}\mathcal{S}\right) \quad (7)$$

$$\approx \exp\left(-\frac{1}{2}(\mathbf{A}\mathcal{S} - \mathbf{x})^\top \Sigma_{\mathcal{X}}^{-1}(\mathbf{A}\mathcal{S} - \mathbf{x}) - \frac{1}{2}\mathcal{S}^\top \Sigma_{\mathcal{S}}^{-1}\mathcal{S}\right) \quad (8)$$

$$\approx \exp\left(-\frac{1}{2}(\mathcal{S}^\top \mathbf{A}^\top - \mathbf{x}^\top)(\Sigma_{\mathcal{X}}^{-1}\mathbf{A}\mathcal{S} - \Sigma_{\mathcal{X}}^{-1}\mathbf{x}) - \frac{1}{2}\mathcal{S}^\top \Sigma_{\mathcal{S}}^{-1}\mathcal{S}\right) \quad (9)$$

$$\approx \exp\left(-\frac{1}{2}\mathcal{S}^\top \mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{A}\mathcal{S} + \mathcal{S}^\top \mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{x} + \frac{1}{2}\mathbf{x}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{x} - \frac{1}{2}\mathcal{S}^\top \Sigma_{\mathcal{S}}^{-1}\mathcal{S}\right) \quad (10)$$

$$\approx \exp\left(-\frac{1}{2}\mathcal{S}^\top (\mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{A} + \Sigma_{\mathcal{S}}^{-1})\mathcal{S} + \mathcal{S}^\top \mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{x} + \frac{1}{2}\mathbf{x}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{x}\right) \quad (11)$$

$$\approx \exp\left(-\frac{1}{2}\mathcal{S}^\top (\mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{A} + \Sigma_{\mathcal{S}}^{-1})\mathcal{S} + \mathbf{x}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{A}\mathcal{S} + \frac{1}{2}\mathbf{x}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{x}\right) \quad (12)$$

Il est clair que la matrice $\mathbf{B} = \mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{A} + \Sigma_{\mathcal{S}}^{-1}$ est une matrice symétrique. D'après l'algèbre linéaire, on a l'égalité suivante :

$$-\frac{1}{2}\mathbf{z}^\top \mathbf{B}\mathbf{z} + \mathbf{h}^\top \mathbf{z} = -\frac{1}{2}(\mathbf{z} - \mathbf{B}^{-1}\mathbf{h})^\top \mathbf{B}(\mathbf{z} - \mathbf{B}^{-1}\mathbf{h}) + \frac{1}{2}\mathbf{h}^\top \mathbf{B}^{-1}\mathbf{h} \quad (13)$$

Alors en substituant (13) dans (12) avec $\mathbf{h}^\top = \mathbf{x}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{A}$ et $\mathbf{z} = \mathcal{S}$, on obtient :

$$p(\mathcal{S}|\mathcal{X}) \approx \exp\left(-\frac{1}{2}(\mathcal{S} - (\mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{A} + \Sigma_{\mathcal{S}}^{-1})^{-1}\mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{x})^\top (\mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{A} + \Sigma_{\mathcal{S}}^{-1})(\mathcal{S} - (\mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{A} + \Sigma_{\mathcal{S}}^{-1})^{-1}\mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1}\mathbf{x})\right)$$

Méthode déterministes pour résoudre un PI

Il est clair que la distribution $p(\mathcal{S}|\mathcal{X})$ est aussi gaussienne avec une moyenne

$$\hat{\mathbf{s}} = (\mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1} \mathbf{A} + \Sigma_{\mathcal{S}}^{-1})^{-1} \mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1} \mathbf{x} \quad (14)$$

Si $\Sigma_{\mathcal{S}} = \sigma_{\mathcal{S}}^2 \mathbf{I}$ et $\Sigma_{\mathcal{X}} = \sigma_{\mathcal{X}}^2 \mathbf{I}$, alors :

$$\hat{\mathbf{s}} = (\mathbf{A}^\top \mathbf{A} + \frac{\sigma_{\mathcal{X}}^2}{\sigma_{\mathcal{S}}^2} \mathbf{I})^{-1} \mathbf{A}^\top \mathbf{x} = (\mathbf{A}^\top \mathbf{A} + \lambda \mathbf{I})^{-1} \mathbf{A}^\top \mathbf{x} \quad (15)$$

avec $\lambda = \sigma_{\mathcal{X}}/\sigma_{\mathcal{S}}$.

Une autre manière pour trouver cette estimation de \mathbf{s} est de maximiser $p(\mathcal{S}|\mathcal{X})$, alors :

$$\begin{aligned} \max_{\mathcal{S}} p(\mathcal{S}|\mathcal{X}) &\Leftrightarrow \min_{\mathcal{S}} f(\mathcal{S}) = -\frac{1}{2} \mathcal{S}^\top \mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1} \mathbf{A} \mathcal{S} + \mathcal{S}^\top \mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1} \mathbf{x} + \frac{1}{2} \mathbf{x}^\top \Sigma_{\mathcal{X}}^{-1} \mathbf{x} - \frac{1}{2} \mathcal{S}^\top \Sigma_{\mathcal{S}}^{-1} \mathcal{S} \\ \Rightarrow \frac{\partial f}{\partial \mathcal{S}} &= -\mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1} \mathbf{A} \mathcal{S} + \mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1} \mathbf{x} - \Sigma_{\mathcal{S}}^{-1} \mathcal{S} = 0 \end{aligned} \quad (16)$$

$$\Rightarrow \frac{\partial f}{\partial \mathcal{S}} = -(\mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1} \mathbf{A} + \Sigma_{\mathcal{S}}^{-1}) \mathcal{S} + \mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1} \mathbf{x} = 0 \quad (17)$$

$$\Rightarrow \hat{\mathcal{S}} = (\mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1} \mathbf{A} + \Sigma_{\mathcal{S}}^{-1})^{-1} \mathbf{A}^\top \Sigma_{\mathcal{X}}^{-1} \mathbf{x} \quad (18)$$

On note que la maximum d'une gaussienne coïncide avec sa moyenne.