

Analyse et Représentation des Signaux (ARSIG)

IV. Représentations parcimonieuses

ECN option DATASIM

Sébastien Bourguignon


`Sebastien.Bourguignon@ec-nantes.fr`

Année 2021-2022




Hypothèse de compressibilité / parcimonie

Un signal / une image / un ensemble de données peut être représenté de manière exacte ou approchée avec un **faible nombre** de coefficients choisis **dans un espace de représentation approprié**.

Synthèse parcimonieuse : $y \simeq Ax$, x essentiellement composé de valeurs nulles






Modèles parcimonieux “naturels”






A

Modèles parcimonieux “naturels”






A

Modèles parcimonieux “naturels”




A

Modèles parcimonieux “naturels”




A

Modèles parcimonieux issus de “transformées”




x = extrait de daphne.wav



$|\text{STFT}(x)|$




x



$|\text{DWT}(x)|$

Représentations parcimonieuses : pourquoi

- Débruitage
- Compression
- Extraction de descripteurs
- Problèmes inverses




- ▶ x parcimonieux directement (train d'impulsions)
- ▶ ou admet une représentation dans un dictionnaire : $x = Au$

Mais aussi...

- Identification de modèles non linéaires [Tang et al., 13]

Modèle non linéaire


$$\mathbf{y} \simeq \sum_{k=1}^K \alpha_k \mathcal{M}(\theta_k)$$



$$\theta_p^d = p \Delta_\theta \rightarrow$$

Modèle discrétisé linéaire + parcimonie

$$\mathbf{y} \simeq \sum_{p=1}^P \mathbf{x}_p \mathcal{M}(\theta_p^d) = \mathbf{M} \mathbf{x}$$



\mathbf{x} parcimonieux : $\mathcal{S} = \{p | x_p \neq 0\}$

$$\leadsto \hat{\theta} = \{\theta_p^d\}_{p \in \mathcal{Q}}$$

$$\leadsto \hat{\alpha} = \{x_p\}_{p \in \mathcal{Q}}$$

$$\leadsto \hat{K} = \text{Card } \mathcal{Q}$$

- Sélection de variables en statistiques [Miller, 02]
- Finance (optimisation de portefeuille) [Gao & Li, 13]
- **Apprentissage de dictionnaires / sparse coding** [Rubinstein et al. 10]
- ...

Calcul de la solution parcimonieuse

- Tous ces problèmes reposent sur la définition / la construction d'un espace de représentation A adapté aux données
 - ▶ Connaissance *a priori* des propriétés du signal / de l'image / des données
 - ▶ Apprentissage de représentations

Calcul de la solution parcimonieuse : étant donnés y et A , comment trouver x ?


- ▶ Simple si A orthogonal
- ▶ En pratique, rarement le cas!

Vocabulaire

- $\mathbf{y} \in \mathbb{R}^N$ vecteur de données
- $\mathbf{x} \in \mathbb{R}^P$ coefficients de la représentation (avec souvent $P > N$)
- $A = [\mathbf{a}_1, \dots, \mathbf{a}_P]$: dictionnaire de P colonnes = atomes
- Représentation parcimonieuse (exacte) : $\mathbf{y} = A\mathbf{x}$ avec \mathbf{x} parcimonieux
- Approximation parcimonieuse (avec bruit) : $\mathbf{y} \simeq A\mathbf{x}$ avec \mathbf{x} parcimonieux

$$A\mathbf{x} = \sum_{p=1}^P x_p \mathbf{a}_p \text{ avec } \mathbf{x} \text{ parcimonieux : } x_p \neq 0 \text{ pour } p \in \underbrace{\{p_1, \dots, p_K\}}_{\text{support de } \mathbf{x}}$$

\leadsto sélection de colonnes actives



- "Norme" ℓ_0 : $\|\mathbf{x}\|_0 = \text{Card}\{p | x_p \neq 0\}$


Formulation de problèmes d'optimisation

Objectif : on cherche le **meilleur** x **parcimonieux** tel que $y \simeq Ax$

$$\leadsto \min_x \frac{1}{2} \|y - Ax\|^2 \quad \text{s.c.} \quad \|x\|_0 \leq K$$

$$\leadsto \min_x \|x\|_0 \quad \text{s.c.} \quad \frac{1}{2} \|y - Ax\|^2 \leq \epsilon$$

$$\leadsto \min_x \frac{1}{2} \|y - Ax\|^2 + \mu \|x\|_0$$



- Complexité *combinatoire* = sélection du **support** de x : $S = \{p | x_p \neq 0\}$


Formulation de problèmes d'optimisation

Objectif : on cherche le **meilleur** x **parcimonieux** tel que $y \simeq Ax$

$$\leadsto \min_x \frac{1}{2} \|y - Ax\|^2 \quad \text{s.c.} \quad \|x\|_0 \leq K$$

$$\leadsto \min_x \|x\|_0 \quad \text{s.c.} \quad \frac{1}{2} \|y - Ax\|^2 \leq \epsilon$$

$$\leadsto \min_x \frac{1}{2} \|y - Ax\|^2 + \mu \|x\|_0$$



- Complexité *combinatoire* = sélection du **support** de x : $S = \{p | x_p \neq 0\}$
- **Optimisation exacte accessible en petite dimension**
 - \leadsto algorithmes Branch-and-Bound [Bienstock 96, Ben Mhenni *et al.* 2020, ...]


Formulation de problèmes d'optimisation

Objectif : on cherche le **meilleur** x **parcimonieux** tel que $y \simeq Ax$

$$\leadsto \min_x \frac{1}{2} \|y - Ax\|^2 \text{ s.c. } \|x\|_0 \leq K$$

$$\leadsto \min_x \|x\|_0 \text{ s.c. } \frac{1}{2} \|y - Ax\|^2 \leq \epsilon$$

$$\leadsto \min_x \frac{1}{2} \|y - Ax\|^2 + \mu \|x\|_0$$




- Complexité *combinatoire* = sélection du **support** de x : $S = \{p | x_p \neq 0\}$
- **Optimisation exacte accessible en petite dimension**
 - \leadsto algorithmes Branch-and-Bound [Bienstock 96, Ben Mhenni *et al.* 2020, ...]
- Sinon :

- \leadsto **optimisation locale** : heuristiques d'exploration combinatoire (partielle)
- \leadsto **relaxations** : résolution d'un problème plus simple

Problème basique : parcimonie dans l'espace des données

■ On suppose $y \simeq x$, avec x parcimonieux ($A = I$)



TD : Comment obtient-on $\hat{x} = \arg \min_x \|y - x\|^2$ tel que $\|x\|_0 \leq K$?

= meilleure approximation de y par x à seulement K valeurs non nulles?

Parcimonie dans une base orthogonale

- On suppose $\mathbf{y} \simeq \mathbf{A}\mathbf{x}$, avec \mathbf{x} parcimonieux et \mathbf{A} carrée orthonormale

Ex : Transformée de Fourier Discrète, TCD, ondelettes orthogonales, ...

$$\min_{\mathbf{x}} \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 \text{ s.c. } \|\mathbf{x}\|_0 \leq K \iff \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{A}^T \mathbf{y} - \mathbf{x}\|^2 \text{ s.c. } \|\mathbf{x}\|_0 \leq K$$

- Procédure d'estimation :

- passage dans l'espace transformé : $\mathbf{z} = \mathbf{A}^T \mathbf{y}$
- seuillage des composantes de $\mathbf{z} \rightsquigarrow \hat{\mathbf{x}}$

Cas général : A transformation quelconque, éventuellement redondante

■ On suppose $y \simeq Ax$, avec x parcimonieux, A non orthogonale et redondante

A redondante : $N_{\text{colonnes}} > N_{\text{lignes}} \leadsto$ possibilités de modélisation ↗

- $A =$ union de bases de propriétés différentes $A = [A_1, \dots, A_M]$

$$y \simeq \begin{bmatrix} A_1 & A_2 & \cdot & \cdot & \cdot & A_M \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \cdot \\ \cdot \\ \cdot \\ x_M \end{bmatrix} = y_1 + \dots + y_M$$

- ▶ Capturer des propriétés complémentaires
- ▶ Séparation en plusieurs composantes y_1, \dots, y_M
- ▶ Exemple : $A = [I, DWT^{-1}]$
- Transformées cohérentes redondantes
(ex. temps-fréquence, paquets d'ondelettes)
 - ▶ Plus de précision dans le modèle

Cas général : A transformation quelconque, éventuellement redondante

■ On suppose $\mathbf{y} \simeq \mathbf{A}\mathbf{x}$, avec \mathbf{x} parcimonieux, \mathbf{A} non orthogonale et redondante

- Pas de formulation explicite (\neq seuillage)
- Infinité de solutions de $\mathbf{y} = \mathbf{A}\mathbf{x}$... non parcimonieuses

TD : Soit $\mathbf{A} = [\mathbf{A}_1, \mathbf{A}_2]$, où \mathbf{A}_1 et \mathbf{A}_2 orthogonales (ex: $\mathbf{A}_1 = \mathbf{I}$, $\mathbf{A}_2 = \text{DWT}^{-1}$).
Quelle solution obtient-on par seuillage de $\mathbf{A}^T \mathbf{y}$?

Cas général : A transformation quelconque, éventuellement redondante

■ On suppose $\mathbf{y} \simeq \mathbf{Ax}$, avec \mathbf{x} parcimonieux, \mathbf{A} non orthogonale et redondante

- Pas de formulation explicite (\neq seuillage)
- Infinité de solutions de $\mathbf{y} = \mathbf{Ax}$... non parcimonieuses

TD : Soit $\mathbf{A} = [\mathbf{A}_1, \mathbf{A}_2]$, où \mathbf{A}_1 et \mathbf{A}_2 orthogonales (ex: $\mathbf{A}_1 = \mathbf{I}$, $\mathbf{A}_2 = \text{DWT}^{-1}$).
Quelle solution obtient-on par seuillage de $\mathbf{A}^T \mathbf{y}$?

TD : Soit \mathbf{A} carrée, inversible, mais non orthogonale.
Quelle solution obtient-on par seuillage de $\mathbf{A}^{-1} \mathbf{y}$?

Optimisation parcimonieuse : algorithmes gloutons

$$\min_x \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 \quad \text{s.c.} \quad \|\mathbf{x}\|_0 \leq K, \quad \min_x \|\mathbf{x}\|_0 \quad \text{s.c.} \quad \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 \leq \epsilon$$

■ Construction itérative d'une solution parcimonieuse (algorithmes "gloutons")

Forward selection [Efroymson, 60]. . .

1. Support $S^{(0)} = \emptyset$, $\mathbf{x}^{(0)} = 0$, résidu $\mathbf{r}^{(0)} = \mathbf{y}$
2. Itération t : choix d'une composante $k^{(t)} \notin S^{(t-1)} \rightarrow S^{(t)} = S^{(t-1)} \cup \{k^{(t)}\}$
3. Calcul des amplitudes $\mathbf{x}_{S^{(t)}}$ et mise à jour du résidu $\mathbf{r}^{(t)} = \mathbf{y} - \mathbf{A}_{S^{(t)}} \mathbf{x}_{S^{(t)}}$
4. $t \leftarrow t + 1$ et retour en 2. jusqu'à $\|\mathbf{r}^{(t)}\| < \epsilon$ ou $\text{Card } S^{(t)} = K$




Optimisation parcimonieuse : algorithmes gloutons

$$\min_x \frac{1}{2} \|y - Ax\|^2 \text{ s.c. } \|x\|_0 \leq K, \quad \min_x \|x\|_0 \text{ s.c. } \frac{1}{2} \|y - Ax\|^2 \leq \epsilon$$

■ Construction itérative d'une solution parcimonieuse (algorithmes "gloutons")

Forward selection [Efroymson, 60]. . .

1. Support $S^{(0)} = \emptyset$, $x^{(0)} = 0$, résidu $r^{(0)} = y$
2. Itération t : choix d'une composante $k^{(t)} \notin S^{(t-1)} \rightarrow S^{(t)} = S^{(t-1)} \cup \{k^{(t)}\}$
3. Calcul des amplitudes $x_{S^{(t)}}$ et mise à jour du résidu $r^{(t)} = y - A_{S^{(t)}} x_{S^{(t)}}$
4. $t \leftarrow t + 1$ et retour en 2. jusqu'à $\|r^{(t)}\| < \epsilon$ ou $\text{Card } S^{(t)} = K$




Optimisation parcimonieuse : algorithmes gloutons

$$\min_x \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 \quad \text{s.c.} \quad \|\mathbf{x}\|_0 \leq K, \quad \min_x \|\mathbf{x}\|_0 \quad \text{s.c.} \quad \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 \leq \epsilon$$

■ Construction itérative d'une solution parcimonieuse (algorithmes "gloutons")

Forward selection [Efroymsen, 60]. . .

1. Support $S^{(0)} = \emptyset$, $\mathbf{x}^{(0)} = 0$, résidu $\mathbf{r}^{(0)} = \mathbf{y}$
2. Itération t : choix d'une composante $k^{(t)} \notin S^{(t-1)} \rightarrow S^{(t)} = S^{(t-1)} \cup \{k^{(t)}\}$
3. Calcul des amplitudes $\mathbf{x}_{S^{(t)}}$ et mise à jour du résidu $\mathbf{r}^{(t)} = \mathbf{y} - \mathbf{A}_{S^{(t)}} \mathbf{x}_{S^{(t)}}$
4. $t \leftarrow t + 1$ et retour en 2. jusqu'à $\|\mathbf{r}^{(t)}\| < \epsilon$ ou $\text{Card } S^{(t)} = K$




Optimisation parcimonieuse : algorithmes gloutons

$$\min_x \frac{1}{2} \|y - Ax\|^2 \text{ s.c. } \|x\|_0 \leq K, \quad \min_x \|x\|_0 \text{ s.c. } \frac{1}{2} \|y - Ax\|^2 \leq \epsilon$$

■ Construction itérative d'une solution parcimonieuse (algorithmes "gloutons")

Forward selection [Efroymson, 60]. . .

1. Support $S^{(0)} = \emptyset$, $x^{(0)} = 0$, résidu $r^{(0)} = y$
2. Itération t : choix d'une composante $k^{(t)} \notin S^{(t-1)} \rightarrow S^{(t)} = S^{(t-1)} \cup \{k^{(t)}\}$
3. Calcul des amplitudes $x_{S^{(t)}}$ et mise à jour du résidu $r^{(t)} = y - A_{S^{(t)}} x_{S^{(t)}}$
4. $t \leftarrow t + 1$ et retour en 2. jusqu'à $\|r^{(t)}\| < \epsilon$ ou $\text{Card } S^{(t)} = K$




Optimisation parcimonieuse : algorithmes gloutons

$$\min_x \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 \quad \text{s.c.} \quad \|\mathbf{x}\|_0 \leq K, \quad \min_x \|\mathbf{x}\|_0 \quad \text{s.c.} \quad \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 \leq \epsilon$$

■ Construction itérative d'une solution parcimonieuse (algorithmes "gloutons")

Forward selection [Efroymson, 60]. . .

1. Support $S^{(0)} = \emptyset$, $\mathbf{x}^{(0)} = 0$, résidu $\mathbf{r}^{(0)} = \mathbf{y}$
2. Itération t : choix d'une composante $k^{(t)} \notin S^{(t-1)} \rightarrow S^{(t)} = S^{(t-1)} \cup \{k^{(t)}\}$
3. Calcul des amplitudes $\mathbf{x}_{S^{(t)}}$ et mise à jour du résidu $\mathbf{r}^{(t)} = \mathbf{y} - \mathbf{A}_{S^{(t)}} \mathbf{x}_{S^{(t)}}$
4. $t \leftarrow t + 1$ et retour en 2. jusqu'à $\|\mathbf{r}^{(t)}\| < \epsilon$ ou $\text{Card } S^{(t)} = K$




Optimisation parcimonieuse : algorithmes gloutons

$$\min_x \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 \text{ s.c. } \|\mathbf{x}\|_0 \leq K, \quad \min_x \|\mathbf{x}\|_0 \text{ s.c. } \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 \leq \epsilon$$

■ Construction itérative d'une solution parcimonieuse (algorithmes "gloutons")

Forward selection [Efroymson, 60]. . .

1. Support $S^{(0)} = \emptyset$, $\mathbf{x}^{(0)} = 0$, résidu $\mathbf{r}^{(0)} = \mathbf{y}$
2. Itération t : choix d'une composante $k^{(t)} \notin S^{(t-1)} \rightarrow S^{(t)} = S^{(t-1)} \cup \{k^{(t)}\}$
3. Calcul des amplitudes $\mathbf{x}_{S^{(t)}}$ et mise à jour du résidu $\mathbf{r}^{(t)} = \mathbf{y} - \mathbf{A}_{S^{(t)}} \mathbf{x}_{S^{(t)}}$
4. $t \leftarrow t + 1$ et retour en 2. jusqu'à $\|\mathbf{r}^{(t)}\| < \epsilon$ ou $\text{Card } S^{(t)} = K$




Optimisation parcimonieuse : algorithmes gloutons

$$\min_x \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 \quad \text{s.c.} \quad \|\mathbf{x}\|_0 \leq K, \quad \min_x \|\mathbf{x}\|_0 \quad \text{s.c.} \quad \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 \leq \epsilon$$

■ Construction itérative d'une solution parcimonieuse (algorithmes "gloutons")

Forward selection [Efroymson, 60]. . .

1. Support $S^{(0)} = \emptyset$, $\mathbf{x}^{(0)} = 0$, résidu $\mathbf{r}^{(0)} = \mathbf{y}$
2. Itération t : choix d'une composante $\mathbf{k}^{(t)} \notin S^{(t-1)} \rightarrow S^{(t)} = S^{(t-1)} \cup \{\mathbf{k}^{(t)}\}$
3. Calcul des amplitudes $\mathbf{x}_{S^{(t)}}$ et mise à jour du résidu $\mathbf{r}^{(t)} = \mathbf{y} - \mathbf{A}_{S^{(t)}} \mathbf{x}_{S^{(t)}}$
4. $t \leftarrow t + 1$ et retour en 2. jusqu'à $\|\mathbf{r}^{(t)}\| < \epsilon$ ou $\text{Card } S^{(t)} = K$



■ Exemple : Orthogonal Matching Pursuit [Pati et al., 93]

2. Choix de la composante la plus adaptée au résidu : $\mathbf{k}^{(t)} = \arg \max_j |\mathbf{a}_j^T \mathbf{r}^{(t-1)}|$
3. Optimisation des amplitudes : $\mathbf{x}_{S^{(t)}} = \arg \min_{\mathbf{x}_S} \|\mathbf{y} - \mathbf{A}_{S^{(t)}} \mathbf{x}_{S^{(t)}}\|^2$


Optimisation parcimonieuse : algorithmes gloutons

$$\min_x \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 \text{ s.c. } \|\mathbf{x}\|_0 \leq K, \quad \min_x \|\mathbf{x}\|_0 \text{ s.c. } \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 \leq \epsilon$$

■ Construction itérative d'une solution parcimonieuse (algorithmes "gloutons")

Forward selection [Efroymsen, 60]...

1. Support $S^{(0)} = \emptyset$, $\mathbf{x}^{(0)} = 0$, résidu $\mathbf{r}^{(0)} = \mathbf{y}$
2. Itération t : choix d'une composante $k^{(t)} \notin S^{(t-1)} \rightarrow S^{(t)} = S^{(t-1)} \cup \{k^{(t)}\}$
3. Calcul des amplitudes $\mathbf{x}_{S^{(t)}}$ et mise à jour du résidu $\mathbf{r}^{(t)} = \mathbf{y} - \mathbf{A}_{S^{(t)}} \mathbf{x}_{S^{(t)}}$
4. $t \leftarrow t + 1$ et retour en 2. jusqu'à $\|\mathbf{r}^{(t)}\| < \epsilon$ ou $\text{Card } S^{(t)} = K$




■ Nombreuses heuristiques [OLS, SBR, COSAMP, ...]

- Choix sous le compromis qualité / complexité calculatoire
- Interférences entre composantes \leadsto chances faibles de retrouver l'optimum global

Optimisation parcimonieuse : relaxations continues


$$\min_{\mathbf{x}} \frac{1}{2} \|\mathbf{y} - \mathbf{Ax}\|^2 + \lambda \underbrace{\|\mathbf{x}\|_0}_{\sum_p 1_{\{x_p \neq 0\}}}$$



Optimisation parcimonieuse : relaxations continues

$$\min_{\mathbf{x}} \frac{1}{2} \|\mathbf{y} - \mathbf{Ax}\|^2 + \lambda \underbrace{\|\mathbf{x}\|_0}_{\sum_p 1_{\{x_p \neq 0\}}} \quad \rightsquigarrow \quad \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{y} - \mathbf{Ax}\|^2 + \lambda \underbrace{\phi(\mathbf{x})}_{\sum_p \varphi(x_p)}$$


avec φ continue, paire, croissante sur \mathbb{R}^+



Optimisation parcimonieuse : relaxations continues

$$\min_x \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 + \lambda \underbrace{\|\mathbf{x}\|_0}_{\sum_p 1_{\{x_p \neq 0\}}} \quad \rightsquigarrow \quad \min_x \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 + \lambda \underbrace{\phi(\mathbf{x})}_{\sum_p \varphi(x_p)}$$

avec φ continue, paire, croissante sur \mathbb{R}^+



La solution est parcimonieuse si et seulement si φ non différentiable en 0

[Moulin & Liu 98]

TD : Parcimonie et non-différentiabilité

La solution est parcimonieuse si et seulement si φ non différentiable en 0

[Moulin & Liu 98]

Optimisation continue non différentiable

$$\min_{\mathbf{x}} \frac{1}{2} \|\mathbf{y} - \mathbf{Ax}\|^2 + \lambda \sum_p \varphi(x_p), \varphi \text{ non différentiable en } 0$$


LE sujet chaud depuis 10 ans / algorithmes parcimonieux! [Bach et al. 12]

Optimisation continue non différentiable

$$\min_x \frac{1}{2} \|\mathbf{y} - \mathbf{Ax}\|^2 + \lambda \sum_p \varphi(x_p), \varphi \text{ non différentiable en } 0$$

LE sujet chaud depuis 10 ans / algorithmes parcimonieux! [Bach et al. 12]

■ Norme ℓ_1 ($\varphi(x_p) = |x_p|$) : critère convexe, géométrie simple




- Beaucoup de stratégies, qui fournissent la même solution
- Efficacité calculatoire dépendante du problème (taille, parcimonie, A)

Optimisation continue non différentiable

$$\min_x \frac{1}{2} \|y - Ax\|^2 + \lambda \sum_p \varphi(x_p), \varphi \text{ non différentiable en } 0$$


LE sujet chaud depuis 10 ans / algorithmes parcimonieux! [Bach et al. 12]

■ Norme ℓ_1 ($\varphi(x_p) = |x_p|$) : critère convexe, géométrie simple



- Beaucoup de stratégies, qui fournissent la même solution
- Efficacité calculatoire dépendante du problème (taille, parcimonie, A)

■ Fonctions non convexes




Optimisation continue non différentiable

$$\min_x \frac{1}{2} \|y - Ax\|^2 + \lambda \sum_p \varphi(x_p), \varphi \text{ non différentiable en } 0$$


LE sujet chaud depuis 10 ans / algorithmes parcimonieux! [Bach et al. 12]

■ Norme ℓ_1 ($\varphi(x_p) = |x_p|$) : critère convexe, géométrie simple



- Beaucoup de stratégies, qui fournissent la même solution
- Efficacité calculatoire dépendante du problème (taille, parcimonie, A)

■ Fonctions non convexes



- Algorithmes d'optimisation *locale* (algorithmes proximaux, ADMM, IRL1, ...)
- Pas de garantie d'optimalité globale... mais fonction de coût plus proche de ℓ_0
- En pratique, résultats souvent meilleurs que ℓ_1 ...


TD : Parcimonie, critères pénalisés et fonctions de seuil

■ Revenons au problème scalaire :


$$\min_x f(x), f(x) = (y - x)^2 + \lambda \varphi(x)$$

- φ induit de la parcimonie $\Leftrightarrow \varphi'(0) \neq 0$
- alors $\psi : y \xrightarrow{\psi} \hat{x}$ est une fonction de seuillage

Fonctions de pénalisation et fonctions de seuillage associées pour $\varphi(x) = |x|^p$



$$\begin{aligned}\phi(x) &= \|x\|_0 \\ \phi(x) &= \|x\|_1 = \sum_k |x_k|\end{aligned}$$




$$\begin{aligned}\psi(z) &= z & \text{si } |z| > \sqrt{\lambda}, 0 \text{ sinon} \\ \psi(z) &= z - \lambda/2 & \text{si } |z| > \lambda/2, 0 \text{ sinon}\end{aligned}$$


Généralisations : parcimonie structurée

■ Prise en compte de contraintes liant les différentes variables

- Parcimonie dans des groupes : $\|\mathbf{x}_{G_i}\|_0 \leq K_i$



- Sélection parcimonieuse de groupes : $x_i = 0 \Leftrightarrow x_j \neq 0, j \in G_i$



ex : *Group LASSO*

$$\min_{\mathbf{x}} \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 + \lambda \sum_j \|\mathbf{x}\|_{G_j}$$


- ...

→ Généralisations des algorithmes gloutons et relaxations (normes mixtes) ...


Généralisations : parcimonie structurée

■ Prise en compte de contraintes liant les différentes variables

- Parcimonie dans des groupes : $\|\mathbf{x}_{G_i}\|_0 \leq K_i$



- Sélection parcimonieuse de groupes : $x_i = 0 \Leftrightarrow x_j \neq 0, j \in G_i$



ex : *Group LASSO*

$$\min_{\mathbf{x}} \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|^2 + \lambda \sum_j \|\mathbf{x}\|_{G_j}$$

- ...

→ Généralisations des algorithmes gloutons et relaxations (normes mixtes) ...
et des approches exactes en norme ℓ_0 ! [Thèse G. Samain]

Généralisations : apprentissage de dictionnaires

Pour un ensemble de données $\mathbf{y}_1, \dots, \mathbf{y}_M$, on cherche un dictionnaire commun de représentation \mathbf{A} tel que

$$\mathbf{y}_m = \mathbf{A}\mathbf{x}_m, \mathbf{x}_m \text{ parcimonieux}$$

- Problème conjoint en $(\mathbf{A}, \mathbf{x}_1, \dots, \mathbf{x}_M)$
- Pas de solution simple, beaucoup de méthodes approchées


Applications $\uparrow\uparrow$ en statistiques / machine learning (*sparse coding*) ...

Application à l'acquisition comprimée (compressed sensing)


⁰<https://www.ima.umn.edu/materials/2006-2007/ND6.4-15.07/3890/baraniuk-IMA-CScamera-june07.pdf>

Application à l'acquisition comprimée (compressed sensing)

■ Exemple : caméra à un pixel! [Baraniuk *et al.*, Rice Univ.]



First Image Acquisition



Cf. cours SIBIO!

Ressources I

■ Parcimonie “historique”

- S. Mallat (2009). *A wavelet tour of signal processing: The sparse way*. Elsevier/Academic Press.

■ Algorithmes

- F. Bach, R. Jenatton, J. Mairal, and G. Obozinski (2011). *Optimization with Sparsity-Inducing Penalties*. Foundations and Trends in Machine Learning.
- A. Miller (2002). *Subset Selection in Regression*, Chapman & Hall/CRC Monographs on Statistics & Applied Probability, CRC Press.
- ℓ_1 ou ℓ_0 : D. Bertsimas, A. King and R. Mazumder (2016). *Best Subset Selection via a Modern Optimization Lens*, Annals of Statistics.
- Une réponse orientée : T. Hastie, R. Tibshirani and R. Tibshirani (2020). *Best Subset, Forward Stepwise or Lasso? Analysis and Recommendations Based on Extensive Comparisons*. Statistical Science.

■ Compressed sensing

- <http://dsp.rice.edu/cs/>
- D.L. Donoho (2006). *Compressed sensing*. IEEE Transactions on Information Theory.
- E.J. Candès & M.B. Wakin (2008). *An Introduction To Compressive Sampling*. IEEE Signal Processing Magazine.
- Y. C. Eldar and G. Kutyniok (2012). *Compressed Sensing: Theory and Applications*, Cambridge University Press.

■ Tutoriels (G. Peyré)

- Numerical tours <http://www.numerical-tours.com/>
- Mathematical tours <https://mathematical-tours.github.io/>

■ Bibliothèques / toolboxes

- SPAMS (SPArse Modeling Software) :
<http://spams-devel.gforge.inria.fr/>
- UNLocBox (optimisation convexe, parcimonie structurée) :
<https://epfl-lts2.github.io/unlocbox-html/>
- Pages web des auteurs

Sebastien.Bourguignon@ec-nantes.fr